

Visão computacional para agricultura de precisão: detecção de pragas com deep learning em ambientes naturais**Computer vision for precision agriculture: pest detection with deep learning in natural environments****Visión computacional para la agricultura de precisión: detección de plagas con aprendizaje profundo en entornos naturales****Anuar José Mincache**

Doutor em Física

Instituição: Centro Universitário Ingá (UNINGÁ)

Endereço: Maringá - Paraná, Brasil

E-mail: prof.anuarmincache@uninga.edu.br

Leandro Boldrin

Graduando em Agronomia

Instituição: Centro Universitário Ingá (UNINGÁ)

Endereço: Maringá - Paraná, Brasil

E-mail: leandro.boldrin@gmail.com

Ana Carolina Gomes Mantovani

Doutora em Física

Instituição: Centro Universitário Ingá (UNINGÁ)

Endereço: Londrina - Paraná, Brasil

E-mail: prof.anamantovani@uninga.edu.br

Lilian Felipe da Silva Tupan

Doutora em Física

Instituição: Centro Universitário Ingá (UNINGÁ)

Endereço: Maringá - Paraná, Brasil

E-mail: prof.liliantupan@uninga.edu.br

RESUMO

Este trabalho propõe uma abordagem experimental com o uso de inteligência artificial para o reconhecimento de pragas em ambientes agrícolas, utilizando redes neurais convolucionais (CNNs). As imagens foram obtidas diretamente no campo, em uma área agrícola situada no norte do Paraná, Brasil, totalizando 1500 registros de três pragas com relevância econômica: *Dalbulus maidis*, *Diabrotica speciosa* e *Euschistus heros*. Para o treinamento e validação do modelo de classificação, foi empregada a arquitetura EfficientNet-B0, que obteve acurácia de 94,2%, além de elevados índices de precisão, especificidade e F1-score. Os resultados demonstram a eficácia das CNNs na identificação de pragas em condições reais de cultivo, indicando sua aplicabilidade em soluções tecnológicas voltadas à agricultura de precisão. O uso dessa abordagem pode ser integrado a dispositivos móveis ou embarcados, contribuindo para o monitoramento

automatizado de lavouras, favorecendo o controle mais eficiente de pragas e promovendo a diminuição da aplicação de defensivos químicos, com ganhos ambientais e econômicos.

Palavras-chave: visão computacional, redes neurais, pragas agrícolas, agricultura de precisão.

ABSTRACT

This study proposes an experimental approach using artificial intelligence for pest recognition in agricultural environments through convolutional Neural Networks (CNNs). The images were collected directly in the field, in an agricultural area located in northern Paraná, Brazil, totaling 1,500 records of three economically significant pests: *Dalbulus maidis*, *Diabrotica speciosa*, and *Euschistus heros*. The EfficientNet-B0 architecture was used to train and validate the classification model, achieving an accuracy of 94.2%, along with high precision, specificity, and F1-score values. The results demonstrate the effectiveness of CNNs in identifying pests under real farming conditions, indicating their applicability in technological solutions aimed at precision agriculture. This approach can be integrated into mobile or embedded systems, contributing to automated crop monitoring, supporting more efficient pest control, and reducing the use of chemical pesticides, thus offering both environmental and economic benefits.

Keywords: computer vision, neural networks, agricultural pests, precision agriculture.

RESUMEN

Este trabajo propone un enfoque experimental con el uso de inteligencia artificial para el reconocimiento de plagas en entornos agrícolas, utilizando redes neuronales convolucionales (CNN). Las imágenes se obtuvieron directamente en el campo, en una zona agrícola situada en el norte de Paraná, Brasil, con un total de 1500 registros de tres plagas de relevancia económica: *Dalbulus maidis*, *Diabrotica speciosa* y *Euschistus heros*. Para el entrenamiento y la validación del modelo de clasificación, se empleó la arquitectura EfficientNet-B0, que obtuvo una precisión del 94,2 %, además de altos índices de precisión, especificidad y F1-score. Los resultados demuestran la eficacia de las CNN en la identificación de plagas en condiciones reales de cultivo, lo que indica su aplicabilidad en soluciones tecnológicas orientadas a la agricultura de precisión. El uso de este enfoque puede integrarse en dispositivos móviles o embarcados, contribuyendo al monitoreo automatizado de cultivos, favoreciendo un control más eficiente de las plagas y promoviendo la reducción de la aplicación de pesticidas químicos, con beneficios ambientales y económicos.

Palabras clave: visión computacional, redes neuronales, plagas agrícolas, agricultura de precisión.

1 INTRODUÇÃO

Os avanços na área de inteligência artificial têm promovido transformações significativas em diversos setores, incluindo a agricultura, possibilitando a automatização de processos, o monitoramento inteligente e a tomada de decisões baseadas em dados (KAMILARIS;

PRENAFETA-BOLDÚ, 2018). No contexto do manejo agrícola, o reconhecimento automático de pragas por meio de técnicas de inteligência artificial destaca-se como uma ferramenta promissora para o aumento da produtividade e para a redução do uso indiscriminado de defensivos químicos (FERENTINOS, 2018; MOHANTY; HUGHES; SALATHÉ, 2016).

A presença de pragas nas lavouras representa uma ameaça constante à produção agrícola mundial, sendo responsável por perdas significativas de safra e pelo uso excessivo de defensivos químicos (OERKE, 2006). Em resposta a esse desafio, pesquisadores têm desenvolvido soluções baseadas em visão computacional e redes neurais convolucionais (CNNs), capazes de identificar pragas a partir de imagens com alta acurácia e eficiência (BRAHIMI; BOUKHALFA; MOUSSAOUI, 2017; LIU *et al.*, 2017).

A aplicação da visão computacional no agronegócio possibilita a análise automatizada de imagens capturadas por drones, câmeras fixas ou dispositivos móveis, permitindo a identificação de padrões associados à presença de insetos, doenças ou estresses fisiológicos nas plantas. Nesse cenário, as redes neurais convolucionais destacam-se pela capacidade de extrair características visuais complexas e discriminantes, sendo amplamente utilizadas em tarefas de classificação e detecção de objetos em ambientes agrícolas (MILIOTO; LOTTES; STACHNISS, 2017; WANG; SUN; WANG, 2017).

Arquiteturas modernas de aprendizado profundo, como YOLO, Faster R-CNN e Efficient Net, vêm sendo adaptadas para operar em condições reais de campo, nas quais fatores como iluminação variável, sobreposição de folhas e ruídos visuais podem comprometer o desempenho dos modelos. A integração dessas arquiteturas com técnicas de pré-processamento e aumento de dados tem se mostrado eficaz na mitigação desses desafios, ampliando a robustez dos sistemas de reconhecimento de pragas (REDMON; FARHADI, 2018; LIN *et al.*, 2021).

Considerando a relevância do uso de IA em ambientes agrícolas este trabalho traz uma abordagem experimental para o reconhecimento de pragas utilizando CNNs, com coleta de dados realizada diretamente no campo, na região norte do Paraná, Brasil. O estudo visa contribuir para o desenvolvimento de soluções práticas e acessíveis que auxiliem os produtores na identificação rápida de pragas, promovendo uma agricultura mais eficiente, sustentável e tecnológica.

2 REVISÃO DA LITERATURA

2.1 CONTROLE DE PRAGAS NA AGRICULTURA

O controle de pragas na agricultura é uma preocupação constante devido ao seu impacto direto na produtividade e na qualidade das culturas. Métodos tradicionais, como o uso intensivo de pesticidas, apresentam problemas ambientais e eficácia limitada a longo prazo, devido à resistência adquirida por algumas espécies (GISI; LEADBEATER, 2010). Soluções sustentáveis e tecnológicas são cada vez mais demandadas, com destaque para a aplicação de IA no monitoramento de pragas.

Redes neurais artificiais, particularmente as redes neurais convolucionais, têm sido utilizadas para a classificação automática de imagens de pragas, proporcionando alta acurácia mesmo em cenários com variações de luz e fundo (KAMILARIS; PRENAFETA-BOLDÚ, 2018; FERENTINOS, 2018). Por exemplo, Chen *et al.* (2020) demonstraram que sistemas baseados em YOLOv3 podem alcançar até 90% de acurácia na identificação de pragas em tempo real.

Além disso, sistemas embarcados de baixo consumo com aceleradores neurais vêm sendo testados para uso em campo, promovendo a detecção autônoma e contínua das infestações (ALBANESE; BIANCO; AMATO, 2021). Essa tecnologia permite uma tomada de decisão mais precisa e localizada, reduzindo o uso desnecessário de pesticidas.

Entretanto, algumas limitações persistem. A escassez de bases de dados bem rotuladas, a variabilidade das condições de campo e a integração com a rotina dos produtores são desafios relevantes (MOHANTY; HUGHES; SALATHÉ, 2016; SLADOJEVIC *et al.*, 2016). Estudos recentes indicam a necessidade de modelos robustos a essas variações e capazes de generalizar para diferentes ambientes agrícolas (KOIRALA *et al.*, 2019).

Adicionalmente, abordagens que integrem inteligência artificial com Internet das Coisas e dispositivos móveis têm potencial de levar a tecnologia diretamente ao produtor, mesmo em regiões remotas (LIN *et al.*, 2021; KAMILARIS; KARTAKOULLIS; PRENAFETA-BOLDÚ, 2017). A prática de big data e o uso de redes generativas também começam a ser considerados em aplicações mais robustas e inteligentes (ZHANG; MENG; LI, 2020; ESPEJO-GARCIA *et al.*, 2020).

Este estudo busca justamente preencher essas lacunas, utilizando dados coletados em campo e propondo um modelo de rede neural convolucional adaptado às condições reais de lavoura (FUENTES *et al.*, 2017).

3 MÉTODO

Este estudo foi conduzido de forma experimental com coleta de dados em campo, em uma região agrícola do norte do estado do Paraná, Brasil, caracterizada por alta diversidade de culturas e elevada incidência de pragas. As imagens foram capturadas em uma área de cultivo sob as coordenadas 23° 48' 04.11"S, 51° 49' 34.66"W. Ao todo, foram obtidas 1500 imagens de alta resolução, sendo 500 para cada uma das três pragas alvo: *Dalbulus maidis* (Cigarrinha-do-milho), *Diabrotica speciosa* (Vaquinha verde e amarela) e *Euschistus heros* (Percevejo-marrom). As imagens foram registradas com câmeras DSLR de 105 megapixels, sob diferentes condições de luz natural e em múltiplos estágios de desenvolvimento das plantas hospedeiras, buscando garantir representatividade visual em situações reais de campo. As pragas foram fotografadas diretamente sobre folhas e caules, preservando sua morfologia natural e sem interferência artificial. Na sequência foi realizado o pré-processamento de imagens de modo que todas as imagens foram redimensionadas para 224x224 pixels, convertidas para escala de cinza (quando apropriado) e normalizadas entre 0 e 1 a fim de otimizar a performance computacional no treinamento.

Sequencialmente foram aplicadas Técnicas de aumento de dados mitigar *overfitting* e aumentar a variabilidade do conjunto de treinamento. Isso incluiu rotações aleatórias de $\pm 15^\circ$, espelhamento horizontal, ajustes de brilho e recorte aleatório (random cropping).

Organização do Dataset (as imagens foram divididas em três conjuntos):

- Treinamento (70%)
- Validação (15%)
- Teste (15%)

A divisão foi feita de forma estratificada, mantendo a proporção por classe (espécie de praga) em cada subconjunto.

Arquitetura da Rede Neural Convolucional (CNN):

Foi adotada a arquitetura *EfficientNet-B0*, uma CNN de última geração que otimiza a acurácia e desempenho computacional. A rede foi inicializada com pesos do *ImageNet* e ajustada (*fine-tuned*) para o novo domínio agrícola. A estrutura incluiu: Camadas convolucionais com *ReLU* e *batch normalization*; Camadas de *pooling* para redução de dimensionalidade; *Dropout* com taxa de 0,3 para regularização; Camada final densa com função *softmax* (3 neurônios, uma para cada classe).

O treinamento foi realizado com otimizador *Adam* com taxa de aprendizado inicial: 0,0001 (*com decay*) e função de perda (*Categorical Crossentropy*). Número de épocas (50), lote (*batch size*): 32, treinamento em GPU (*Google Colab Pro*).

A avaliação do modelo incluiu, acurácia global, precisão (*Precision*), especificidade (*specifity*), F1-Score, Matriz de confusão. Essas métricas foram aplicadas ao conjunto de teste para medir o desempenho do modelo nas três categorias de pragas.

4 RESULTADOS E DISCUSSÕES

4.1 CARACTERIZAÇÃO DA COLETA DE DADOS

Coleta 01:

- Praga: *Dalbulus maidis*
- Localização: 23° 47' 55.95"S, 51° 49' 34.66"W
- Características: Inseto branco-palha (Figura 1), 3 a 4 mm, se alimenta da seiva do milho.

Figura 1. Cigarrinha-do-milho (*Dalbulus maidis*): inseto de 3–4 mm, branco-palha, que se alimenta da seiva do milho e ovipõe sob a epiderme das folhas jovens.



Fonte: elaborada pelo autor (2025)

Coleta 02

- Praga: *Diabrotica speciosa*
- Localização: 23° 47' 55.95"S, 51° 49' 34.66"W
- Características: Inseto polífago que ataca folhas, vagens e frutos, transmissor de vírus (Figura 2).

Figura 2. Vaquinha verde e amarela (*Diabrotica speciosa*): praga polífaga presente em todo o Brasil, alimenta-se de folhas e frutos, reduz a produtividade e transmite patógenos, especialmente vírus.




Fonte: elaborada pelo autor (2025)

Coleta 03

- Praga: *Euschistus heros*
- Localização: 23° 47' 55.95"S, 51° 49' 34.66"W
- Características: Percevejo comum (Figura 3) em culturas de soja, milho e algodão, presente em regiões quentes.

Figura 3. Percevejo-marrom (*Euschistus heros*): importante praga da soja, também ataca algodão, feijão, milho e girassol, predominando em regiões mais quentes do Brasil.




Fonte: elaborada pelo autor (2025)

Esse processo completo permitiu a construção de um sistema de classificação robusto, com potencial de aplicação direta no campo por meio de dispositivos móveis ou embarcados.

Os resultados obtidos por meio do modelo de rede neural convolucional *EfficientNet-B0* indicam um desempenho altamente satisfatório na tarefa de reconhecimento automático de pragas agrícolas em imagens capturadas diretamente no campo. A acurácia global de 94,2% no conjunto de teste, associada a valores equilibrados de precisão, especificidade e F1-score para todas as classes, demonstra que a arquitetura adotada é capaz de capturar e generalizar padrões visuais relevantes, mesmo diante de variações ambientais, como iluminação natural e sobreposição de elementos da lavoura.

No gráfico 1 é apresentado os valores médios de desempenho do modelo para as métricas principais. Esses valores indicam que o sistema apresenta consistência estatística, o que é fundamental para aplicações operacionais em campo, onde a variabilidade nas condições de captura de imagem é alta.


Gráfico 1. Desempenho médio do modelo nas métricas: Acurácia, Precisão, Especificidade e F1-score.



Fonte: elaborada pelo autor (2025)

A maior especificidade foi observada na detecção da praga *Dalbulus maidis* (96,3%), sugerindo que o modelo tem excelente capacidade de evitar falsos positivos, ou seja, identificar corretamente a ausência dessa praga em imagens de outras categorias. Isso possivelmente se deve à sua morfologia distinta e coloração mais contrastante com as folhas de milho, facilitando sua segmentação automática (LIU *et al.*, 2017). Por outro lado, a leve queda na especificidade de *Diabrotica speciosa* (91,4%) pode estar relacionada ao padrão cromático mais semelhante ao ambiente de fundo, como folhas amareladas ou danificadas, o que gera ambiguidade em alguns casos — evidenciada na matriz de confusão (Figura 4), onde houve confusão cruzada entre *Dalbulus maidis* e *Diabrotica speciosa*.

Figura 4. Matriz de confusão indicando acertos e erros por classe.




Fonte: elaborada pelo autor (2025)

Esse tipo de erro está alinhado com a literatura, que aponta que redes neurais convolucionais, apesar de eficazes, são sensíveis a variações visuais contextuais, especialmente em ambientes ruidosos como lavouras (MOHANTY; HUGHES; SALATHÉ, 2016). Para mitigar esse efeito, propõe-se, como trabalhos futuros, o uso de arquiteturas mais profundas com mecanismos de atenção espacial, como EfficientNetV2 ou ResNeSt, bem como a integração de dados multiespectrais, que podem ampliar a discriminação entre diferentes tipos de insetos mesmo em condições visuais semelhantes (LIN *et al.*, 2021; ESPEJO-GARCIA *et al.*, 2020).

No gráfico 2 é mostrada a curva de perda (*loss*) ao longo das épocas de treinamento, demonstrando que o modelo convergiu de maneira estável. A perda de validação reduziu-se progressivamente até cerca da 35ª época e manteve-se estável até a 50ª, o que indica ausência de *overfitting*. Essa estabilidade foi resultado da aplicação de regularizações eficazes como *dropout*, e do uso de técnicas de aumento de dados (*data augmentation*), que ampliaram a variabilidade do conjunto de treino mesmo com uma base relativamente limitada.

Gráfico 2. Curvas de perda durante o treinamento e validação da CNN.



Fonte: elaborada pelo autor (2025)

Do ponto de vista prático, os resultados indicam que o modelo pode ser implementado em sistemas de monitoramento agrícola em tempo real, contribuindo diretamente para o controle localizado de pragas e para a redução no uso de pesticidas. Esse tipo de aplicação é particularmente relevante no contexto da agricultura de precisão sustentável, conforme recomendado por estudos que analisam sua eficácia em diferentes escalas produtivas (KAMILARIS; PRENAFETA-BOLDÚ, 2018; FERENTINOS, 2018; WANG; SUN; WANG, 2017).

Outro aspecto relevante é a capacidade do modelo de operar com imagens capturadas em condições reais de campo, característica que nem sempre é contemplada em estudos anteriores. Muitos trabalhos utilizam imagens coletadas em ambientes controlados ou bancos de dados públicos, o que limita a aplicabilidade prática dos modelos (BRAHIMI; BOUKHALFA; MOUSSAOUI, 2017; SLADOJEVIC *et al.*, 2016). Neste estudo, as imagens foram obtidas diretamente no ambiente agrícola, com pragas registradas em situações naturais, reforçando o caráter experimental, replicável e escalável da abordagem.

Além disso, o tempo médio de inferência por imagem foi de 78 ms em GPU, o que demonstra a viabilidade do modelo para aplicações em dispositivos móveis, câmeras embarcadas ou drones. Essa viabilidade operacional representa um diferencial importante para a adoção

tecnológica no setor agropecuário, inclusive por pequenos produtores com acesso limitado a infraestrutura computacional avançada (KOIRALA *et al.*, 2019).

Em termos de aplicabilidade, os resultados apresentados validam o potencial da rede *EfficientNet-B0* como núcleo de um sistema inteligente de apoio à tomada de decisão no campo, viabilizando um reconhecimento automatizado, rápido e preciso das pragas mais relevantes na agricultura brasileira. O desenvolvimento de um aplicativo embarcado ou plataforma de monitoramento contínuo pode ampliar o impacto prático desta pesquisa, otimizando o uso de defensivos, preservando o ambiente e aumentando a rentabilidade da produção.

5 CONSIDERAÇÕES FINAIS/CONCLUSÕES

Os resultados apresentados evidenciam que a aplicação da rede neural convolucional *EfficientNet-B0* constitui uma solução promissora para o reconhecimento automático de pragas agrícolas em condições reais de campo. A elevada acurácia global, aliada à estabilidade observada durante o treinamento e à consistência das métricas de desempenho, demonstram que o modelo é capaz de lidar com as variabilidades inerentes ao ambiente agrícola, como alterações na iluminação e interferências visuais. Além disso, a viabilidade operacional, refletida no baixo tempo médio de inferência, reforça o potencial de integração dessa abordagem em sistemas móveis, viabilizando o monitoramento em tempo real.

REFERÊNCIAS

- ALBANESE, A.; BIANCO, S.; AMATO, G. **A deep learning approach for detecting plant diseases and pests in agricultural environments.** *Computers and Electronics in Agriculture*, v. 187, p. 106288, 2021.
- BRAHIMI, M.; BOUKHALFA, K.; MOUSSAOUI, A. **Deep learning for tomato diseases: Classification and symptoms visualization.** *Applied Artificial Intelligence*, v. 31, n. 4, p. 299–315, 2017.
- CHEN, Y. *et al.* **Real-time insect pest detection using deep learning-based object detection models.** *Sensors*, v. 20, n. 12, p. 1–17, 2020.
- ESPEJO-GARCIA, B. *et al.* **Machine learning for crop disease classification: A systematic review.** *Computers and Electronics in Agriculture*, v. 178, p. 105783, 2020.
- FERENTINOS, K. P. **Deep learning models for plant disease detection and diagnosis.** *Computers and Electronics in Agriculture*, v. 145, p. 311–318, 2018.
- FUENTES, A. *et al.* **A robust deep-learning-based detector for real-time tomato plant diseases and pests recognition.** *Sensors*, v. 17, n. 9, p. 1–21, 2017.
- GISI, U.; LEADBEATER, A. **The challenges of chemical control of plant diseases.** *Crop Protection*, v. 29, n. 9, p. 961–969, 2010.
- KAMILARIS, A.; KARTAKOULLIS, A.; PRENAFETA-BOLDÚ, F. X. **A review on the practice of big data analysis in agriculture.** *Computers and Electronics in Agriculture*, v. 143, p. 23–37, 2017.
- KAMILARIS, A.; PRENAFETA-BOLDÚ, F. X. **Deep learning in agriculture: A survey.** *Computers and Electronics in Agriculture*, v. 147, p. 70–90, 2018.
- KOIRALA, A. *et al.* **Deep learning for real-time fruit detection and orchard fruit load estimation.** *Computers and Electronics in Agriculture*, v. 156, p. 1–11, 2019.
- LIN, K. *et al.* **Internet of Things-based smart agriculture: Toward next-generation agricultural systems.** *IEEE Internet of Things Journal*, v. 8, n. 4, p. 1–12, 2021.
- LIU, B. *et al.* **Identification of apple leaf diseases based on deep convolutional neural networks.** *Symmetry*, v. 9, n. 1, p. 11, 2017.
- MILIOTO, A.; LOTTES, P.; STACHNISS, C. **Real-time semantic segmentation of crop and weed for precision agriculture robots leveraging background knowledge in CNNs.** In: *2017 IEEE International Conference on Robotics and Automation (ICRA)*. Singapore: IEEE, 2017. p. 2229–2235.
- MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. **Using deep learning for image-based plant disease detection.** *Frontiers in Plant Science*, v. 7, p. 1–10, 2016.

OERKE, E. C. **Crop losses to pests.** *Journal of Agricultural Science*, v. 144, n. 1, p. 31–43, 2006.

REDMON, J.; FARHADI, A. **YOLOv3: An incremental improvement.** *arXiv preprint*, arXiv:1804.02767, 2018.

SLADOJEVIC, S. et al. **Deep neural networks based recognition of plant diseases by leaf image classification.** *Computational Intelligence and Neuroscience*, v. 2016, p. 1–11, 2016.

TAN, M.; LE, Q. **EfficientNet: Rethinking model scaling for convolutional neural networks.** In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. Long Beach: PMLR, 2019. p. 6105–6114.

WANG, G.; SUN, Y.; WANG, J. **Automatic image-based plant disease severity estimation using deep learning.** *Computational Intelligence and Neuroscience*, v. 2017, p. 1–8, 2017.

ZHANG, C.; MENG, Q.; LI, Z. **Data augmentation and generative adversarial networks for agricultural image analysis.** *Computers and Electronics in Agriculture*, v. 172, p. 105334, 2020.

